

基于图神经网络的方面级情感分析*

张合桥, 苟 刚[†], 陈青梅

(贵州大学 计算机科学与技术学院, 贵州 550025)

摘要: 目前基于循环神经网络和注意力机制的方面级情感分析模型缺乏解释相关句法约束和远程单词依赖关系。针对该问题提出结合句子依存树和单词序列信息建立句子关系图模型。首先将句子表示为图, 单词作为图的节点, 依存句法树的边和单词序列作为图的边; 然后提出邻接矩阵标记方案对句子关系图进行标记; 最后利用图神经网络实现节点和边的分类任务。该模型在 SemEval2014 任务中的 restaurant 和 laptop 两个数据集上进行实验, 在两个数据集上 F_1 值提升了 5% 左右。实验结果表明, 将句子转换成图利用图神经网络对句子进行方面级情感分析是有益的。

关键词: 方面级情感分析; 情感分析; 图神经网络; 自然语言处理

中图分类号: TP391 **文献标志码:** A **文章编号:** 1001-3695(2021)12-009-3574-07

doi: 10.19734/j.issn.1001-3695.2021.05.0166

Aspect-based sentiment analysis based on graph neural network

Zhang Heqiao, Gou Gang[†], Chen Qingmei

(College of Computer Science & Technology, Guizhou University, Guizhou 550025, China)

Abstract: Most aspect sentiment analysis is based on recurrent neural networks and attention mechanisms, and these models lack a mechanism to account for relevant syntactical constraints and long-range word dependencies. To tackle this problem, this paper proposed a sentence relationship graph model based on sentence dependency tree and word sequence information. Firstly, it transformed the sentence into a graph, constructed the words as nodes of the graph, and the edges in the graph were composed of word dependency and word sequence information. Then it proposed an adjacency matrix tagging scheme to mark the sentence relation graphs. Finally, it used graph neural network to realize the classification task of nodes and edges. This model was tested on two datasets of restaurant and laptop in SemEval2014, and the classification F_1 -score of the two datasets was increased by about 5%. The experimental results show that it is beneficial to transform sentences into graphs and use the graph neural network to perform aspect-based sentiment analysis on sentences.

Key words: aspect-based sentiment analysis(ABSA); sentiment analysis; graph neural network; natural language processing

0 引言

方面级情感分析(ABSA)也称特定目标情感分析,是一种细粒度情感分析任务^[1],其目的是分析句中特定方面项的情感极性,子任务主要包括方面项抽取、观点项抽取和方面项情感分类。Zhang 等人^[2]联合抽取方面项、观点项和情感极性并将其作为方面级情感分析任务中新子任务命名为观点三元组抽取(opinion triplet extraction, OTE)。例如句子:“The food, though served with bad service is actually great.”中方面项 food 对应的观点项为 great 表达的情感是积极的,方面项 service 对应的观点项为 bad 表达消极情感。通常情况下,该任务被表述为由方面项、观点项和情感极性组成的三元组。鉴于人工设计特征效率低下^[3],早期的方面级情感分析主要是基于神经网络^[4]。尤其是 Tang 等人^[5]提出在上下文与方面词之间建立语义相关性的挑战以来,基于注意力机制和循环神经网络的模型在方面级情感分析任务中扮演着重要角色。如 Wang 等人^[6]提出使用基于注意力网络的 LSTM 来识别与目标方面有关的重要情感信息。Chen 等人^[7]介绍一种利用多层注意力机制捕获长距离方面与观点依赖信息。Fan 等人^[8]提出一个具有细粒度和粗粒度注意力的多粒度注意力网络。文献[9]提

出用注意力机制计算文本编码的多个语义编码。虽然基于注意力机制和循环神经网络的模型在方面级情感分析中取得了巨大成功,但这些模型不足以捕捉句中上下文与方面项之间的依赖关系。相反,注意力机制会错误地将与方面项无关的上下文词作为方面项的重要情感来源。例如“its size is ideal and the weight is acceptable.”中注意力会将 acceptable 判定为方面项 size 的观点描述,这是错误的。为解决这个问题,He 等人^[10]提出对注意力权重施加一些句法约束,但句法结构的效果未能得到充分的利用。

最近,利用图神经网络与依存句法树相结合的模型在 ABSA 任务中取得了很好的效果,图神经网络在 ABSA 中具有很强的表现效果。文献[11]提出利用图卷积网络在依存句法树上学习节点表示,并将得到的节点表示和其他特征一起用于情感分类。同样,Huang 等人^[12]使用依存关系图直接从方面目标的句法上下文传播情感特征。Wang 等人^[13]通过修剪依存句法树定义一个面向方面的依赖树结构,对新的树进行编码已达到情感预测的目的。虽然,这些方法有效地将图神经网络与依存语法树相结合,但忽视了句子中单词本身的序列关系。

为保留句子本身携带的信息特征,本文提出一种句子关系图。通过在依存句法树上添加单词序列信息构建句子关系图,提出关系距离权重作为句法约束,然后在句子关系图上应用图

收稿日期: 2021-05-13; 修回日期: 2021-06-28 基金项目: 国家自然科学基金资助项目(61562009); 贵州省自然科学基金资助项目(黔科合基础[2019]1088)

作者简介: 张合桥(1993-),男,贵州毕节人,硕士,主要研究方向为机器学习、深度学习、自然语言处理; 苟刚(1979-),男(通信作者),贵州贵阳人,副教授,硕士,主要研究方向为模式识别、云计算(6706605@qq.com); 陈青梅(1995-),女,贵州仁怀人,硕士,主要研究方向为强化学习、自然语言处理。

神经网络学习节点表示从而实现节点和边分类。

1 句子关系图及关系距离

1.1 句子关系图

大多数方面级情感分析模型是将句子视为序列问题,通过不同的神经网络将方面项信息嵌入到句子表示中。如 Huang 等人^[14]将方面信息融合到卷积神经网络中从而实现情感分类。这种方法很大程度上忽视了句子的句法结构,与普通情感分析不同,方面级情感分析不仅依赖句子中单词间序列信息,还依赖词语之间的关系信息,同一个句子的不同方面可能具有完全相反的情感极性。因此,ABSA 分类任务的性能瓶颈主要来自于模型的表示,即有效地编码句中特定方面项和观点项之间的联系是该任务的核心。目前很多研究明确利用依存句法树建立这种联系,语法结构有助于直接指向方面项的情感特征,利用依存句法树分析句子中方面项与观点项之间的关系是当前被证实最有效的方法。以句子“The food, though served with bad service is actually great.”为例,其依存树如图 1 所示,从中很容易将方面项与其表达情感极性的观点项关联在一起。若不使用依存句法树按句子中单词序列很容易将 food 的观点词视为 bad、service 的观点词视为 great,按位置感知容易得到 food 和 service 的观点词都为 bad 这种错误的情感极性。从该例中可以看出在处理方面级情感分析任务时不能忽视句子本身依存句法关系,同样,一个句子中单词出现的顺序直接影响着句子的表达,前后两个单词的位置对换会表达出完全相反的意思,所以在方面级情感分析中单词序列也是不可忽视的一个重要信息。

S: The food, though served with bad service, is actually great.

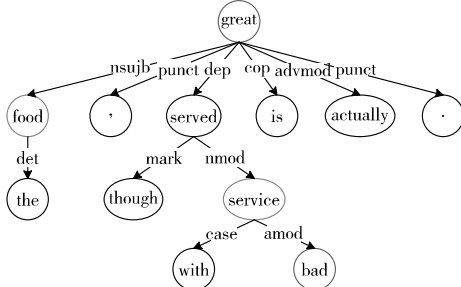


图 1 句子的依存树结构

Fig. 1 Dependency tree structure for sentence

综上所述,依存句法关系和句子中单词序列信息是词语间关系表达的重要信息来源,将单词序列信息作为边添加到依存句法树上即可构建如图 2 所示的句子关系。在句子关系图中方面级情感分析任务转换为节点和边的分类任务,即节点分为方面项节点、观点项节点和其他节点。图 2 中方面项节点有 food 和 service,关系项节点有 great 和 bad,剩余的归为其他类节点。

边作为情感类别分为积极边、消极边、中性边和其他边,图 2 中积极边为 (food, great)、消极边为 (service, bad)、其余属于其他边。从节点、边分类结果可得方面级情感分类三元组 (方面、观点和极性) 关系。

1.2 最大关系子图和最小关系子图

Wang 等人^[13]提出利用依存句法处理方面级情感分析时,通常只有目标词周边的单词才对目标词有影响,所以 Wang 等人^[13]通过修剪普通依存句法树定义了一个以目标方面为基础的面向方面的依存树,虽然在修剪过程中会丢失部分信息但是该方法取得了很好的效果。受此启发,同样在句子关系图中目标节点受其邻居节点影响最大,因此对句子关系图进行修剪构建新的关系图是有必要的。通常一个句子中会包含一个或多个方面项,根据是否将一个句子修剪成一个子图或按照句子中

方面观点对修剪成多个子图可分为最大关系子图和最小关系子图。最大关系子图的构建即保留关系图中方面项和观点项的邻居节点和边,删除其余节点和边,如图 3 为图 2 的最大关系子图。由图 3 可知,though 属于无相关的节点,故在最大关系子图中将其删除。最小关系子图是以方面观点对为中心,保留其邻居节点和边,对于图 2 的句子关系图有两个最小关系子图,分别为图 4 (a) 和 (b) 所示,图 4 (a) 为以方面观点对 food、great 为中心的最小关系子图,图 4 (b) 为以 service、bad 为中心的最小关系子图。构建最大关系子图和最小关系子图的目的在于消除图中无关节点和边,从而使模型更加关注于与方面项和观点项有关的节点和边。




图 2 句子关系
Fig. 2 Relation graph for sentence




图 3 最大关系子图
Fig. 3 Max relation subgraph





图 4 最小关系子图
Fig. 4 Min relation subgraph

1.3 关系距离权重

句子关系图中包含单词序列信息和依存信息。通常,句子中描述方面情感的词往往离该方面项的位置很近,即在方面级情感分析中单词与目标词之间的位置隐含着重要的信息,且离目标词越近的词对目标词的影响越大。由于句子情感表达往往是一个复杂的语法结构,这种结构不仅包括单词间序列信息也包括复杂的依存结构,所以为刻画句子中单词对目标词的依赖关系,下面将单词与目标词之间关系距离定义在句子关系图上,关系距离定义为句子关系图中以目标词为中心向其邻居节点距离递减的过程。即对于有 k 个节点的句子关系图 G 其图上第 i 个目标词 a_i 与其第 n 层邻居节点之间的关系距离为

$$d_{a_i n_i} = \frac{1}{n_i} \quad 1 \leq n_i < k \quad (1)$$

其中: i 为图 G 中目标词个数; a_i 为 G 中第 i 个目标词; n_i 为第 i 个目标词的第 n 层。关系距离定义为图 G 中所有目标词的关系距离之和 D_G 为

$$D_G = \sum_{j=1}^i (d_{a_i n_i})_j \quad (2)$$

以图 1 句子中目标词 food、great、service 和 bad 为例,其关系距离如图 5 所示。

$$w_e = \tan \left[\left(\frac{\sum_{i=1}^n (D_G) - \left(\sum_{i=1}^n (D_G) \right)_{\min}}{\left(\sum_{i=1}^n (D_G) \right)_{\max} - \left(\sum_{i=1}^n (D_G) \right)_{\min}} \right)^3 \right] \quad (3)$$

为使关系距离能有效地应用在模型中将关系距离进行式 (3) 的处理得到边的关系距离权重 w_e 。

2 邻接矩阵标记方案

邻接矩阵是表示顶点之间相邻关系的矩阵,受文献 [15] 启发提出针对句子关系图的标记方案并将其命名为邻接矩阵标记方案。与现有标记方案不同,该方案不仅标记节点也标记

边适用于图结构。设图 $G=(V,E)$ 中节点 V 的标签为 V' , 边 E 的标签为 E' , 则 $V' \in (A, O, N)$ 表示图中节点的标签, A 标记方面词节点、 O 标记观点词节点、 N 表示其他节点, $E' \in (Pos, Neg, Neu, N)$ 表示图中边的标签, 若边上两节点表示的情感极性为积极则该边被标记为 Pos 、若为消极则标记为 Neg 、若为中性则标记为 Neu 、若边上两个节点没有极性表达则标记为 N 。在邻接矩阵标记方案中若两节点之间没有边则用 $/$ 表示。特别地, 对于邻接矩阵标记方案中每一个节点都有自环边, 其标记为该节点自身的标签。本文构建的句子关系图皆为无向图, 因此邻接矩阵标记方案有以下特征: a) 邻接矩阵标记为对称阵, 故邻接矩阵标记取右上部分; b) 对角线表示对应节点标记, 非对角线即第 i 行第 j 列交叉处表示对应节点边的标记。以图2句子关系图为例, 其邻接矩阵标记如图6所示。




图5 关系距离
Fig. 5 Relative distance

| | | | | | | | | | | | | | | | | | | | | | | | | | |
|--|---|---|---|---|---|---|-----|---|---|---|---|---|--|---|---|---|---|---|---|---|---|---|---|---|----------|
| The food, though served with bad service, is actually great. | | | | | | | | | | | | | The food, though served with bad service, is actually great. | | | | | | | | | | | | |
| N | N | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | N |
| | A | N | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | pos |
| | | N | N | / | / | / | / | N | N | N | / | / | / | / | / | / | / | / | / | / | / | / | / | / | N |
| | | | N | N | / | / | / | / | N | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | though |
| | | | | N | N | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | served |
| | | | | | N | N | N | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | with |
| | | | | | | O | neu | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | bad |
| | | | | | | | | A | N | / | / | / | / | / | / | / | / | / | / | / | / | / | / | / | service |
| | | | | | | | | | N | N | / | / | / | / | / | / | / | / | / | / | / | / | / | / | , |
| | | | | | | | | | | N | N | / | / | / | / | / | / | / | / | / | / | / | / | / | is |
| | | | | | | | | | | | N | N | / | / | / | / | / | / | / | / | / | / | / | / | actually |
| | | | | | | | | | | | | O | N | / | / | / | / | / | / | / | / | / | / | / | great |
| | | | | | | | | | | | | | | N | / | / | / | / | / | / | / | / | / | / | . |

图6 邻接矩阵标记方案
Fig. 6 Adjacency matrix tagging scheme

3 句子关系图模型

3.1 任务定义

给定一个由 k 个单词组成的句子 $S=(w_1, w_2, \dots, w_k)$, 其中 $k>0$, 句子关系图被定义为 $G=(V,E)$, V 为图中节点集即句子中单词集且 $V \in (w_1, w_2, \dots, w_k)$, E 为边集, 设图 G 中边集 E 的大小为 z , 一条边 (u,v) 连接一对节点 u 和 v 且 $u \in (w_1, w_2, \dots, w_k)$, $v \in (w_1, w_2, \dots, w_k)$ 。对于方面和观点抽取任务在图中被视为节点级任务, 节点级任务是抽取图 G 节点中方面项节点和观点项节点。方面项情感分类任务被视为图 G 中边分类任务, 而边分类任务被定义为图中三元组关系 (n_a, n_o, r) , r 为方面项节点 n_a 在观点项节点 n_o 影响下表现出的极性即两节点边上的标签。模型的任务是实现节点和边的分类, 以图1中给出句子为例, 其节点级任务是找出 food、great、service 和 bad 节点, 边级任务是找出 (food, great, pos) 和 (service, bad, neg) 的三元组关系。

3.2 模型定义

为解决句子关系图中两个任务, 本文提出一种基于图神经

网络的句子关系图模型 SRG(sentence relation graph model) 根据节点聚合方式的不同 SRG 模型可分为 SRG-mean 和 SRG-BiLSTM 模型结构如图7所示。SRG 模型包括三层:

a) 输入层。主要对数据集进行预处理, 将数据集中句子转换成图的过程, 包括利用依存句法分析器获取句子依存树, 在依存树基础上添加单词序列构成句子关系图, 计算关系距离, 将单词作为句子关系图中节点特征, 依存句法树上的依存关系作为图中边特征, 对节点和边进行标记。然后利用 GloVe 词嵌入^[16]将句子关系图中节点特征(单词)映射成对应的词向量表示, 边特征(依存关系)映射成低维向量表示。

b) 图网络层。该层主要包括节点编码和边的聚合, 对于节点级任务 SRG 模型在使用邻居节点进行更新时分别采用 GraphSAGE 模型^[17]中对邻居节点聚合并更新目标节点的方法。在边级任务中, SRG 模型将由节点级任务中获得的节点表示与边上特征进行聚合形成新的特征以便更新边特征。

c) 输出层。针对节点和边的特征利用 softmax 层输出节点和边分类。

3.3 输入层

输入层主要对句子 $S=(w_1, w_2, \dots, w_k)$ 进行预处理, 目的是将数据集中句子转换成句子关系图的过程, 具体包括:

a) 句子关系图构建。根据 1.1 节所述, 影响句子表达的两个重要因素分别是单词之间序列信息和依存关系信息, 为使模型能充分学习到句子隐含表达, 故对句子 S 进行依存句法分析同时在依存句法树上添加单词的顺序信息从而构成以单词为节点和以依赖关系、单词顺序为边的句子关系图 $G=(V,E)$, 句子关系图在最大程度上保证了句子本身信息特征, 为模型的学习提供完整全面的信息。但在一个句子中不是所有单词都对目标词有影响, 相反有些单词会影响到模型学习效果, 所以在句子关系图构建基础上分别构建最大关系子图和最小关系子图, 以探索不同关系图对模型学习的影响。

b) 关系距离权重。关系距离权重主要作为以 mean 聚合器聚合邻居节点特征更新目标节点特征的权重值, 其构建在句子关系图上, 包含句子顺序距离和依赖距离, 其算法如 1.3 节所述, 针对每一个句子关系图 G 都能得到一个关系距离权重 w_e 。

c) 词向量表示。假设图 G 中节点 v 上的特征为 $x_v \in \mathbb{R}^d$, 边 (u,v) 上的特征为 $e_{uv} \in \mathbb{R}^d$, 那么词向量表示即将图 G 中每一个节点和边特征映射为一个连续低维稠密且带语义的实数向量。对于句子 $S=(w_1, w_2, \dots, w_k)$, 若 $N \in \mathbb{R}^{|V| \times d}$ 为 GloVe 词嵌入的向量表, $|V|$ 表示词汇表 N 的大小, d 为词向量维度。则节点 v 的特征 $x_v = N(w_i) \in \mathbb{R}^{1 \times d}$ 表示 w_i 所对应的词向量表示, 即将句子 S 转换为一个 $k \times d$ 的向量矩阵 $S_D = (w_1^d, w_2^d, \dots, w_k^d)$ 。同理, 对于边 (u,v) 上的依赖关系特征对应的词向量为 $e_{uv} = N(e_{ij}) \in \mathbb{R}^{1 \times d}$ 。因此图 G 中节点特征为 $x_v = N(w_i) \in \mathbb{R}^{1 \times d}$, 边特征为 $e_{uv} = N(e_{ij}) \in \mathbb{R}^{z \times d}$, 边上关系距离权重为 w_e 。

3.4 图网络层

图网络层的任务包括节点更新和边聚合。节点更新和边聚合遵从图神经网络中消息传递范式, 式(4)为边上计算范式, 式(5)为节点上计算范式。

$$m_e^{(t+1)} = \phi(x_v^t, x_u^t, e_{uv}^t) \quad (u,v) \in \mathcal{E} \quad (4)$$

$$x_v^{(t+1)} = \varphi(x_v^t, \rho(\{m_e^{(t+1)} : (u,v) \in \mathcal{E}\})) \quad (5)$$

其中: ϕ 为定义在每条边上的消息函数, 通过结合边两端上节点特征与边特征生成消息; ρ 为聚合函数, 用于聚合节点接收到的消息; φ 为更新函数, 更新函数会结合聚合后的消息和节点本身的特征来更新节点的特征; ρ 表示将右边产生的结果赋给左边的变量; $m_e^{(t+1)}$ 为聚合后产生的消息, 节点更新和边聚合规范分别如图8(a)(b)所示。

a) 节点更新。为实现句子关系图中节点更新, 本文根据

句子关系图的特征对 GraphSAGE^[17] 模型中提到的 MEAN 聚合

器和 LSTM 聚合器作以下调整:

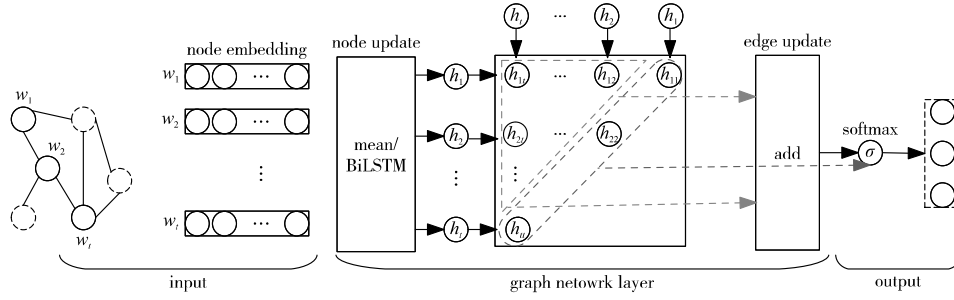


图 7 句子关系图模型

Fig. 7 Sentence relation graph model




图 8 更新节点与边聚合

Fig. 8 Node update and edge aggregation

(a) 添加关系距离权重的 MEAN aggregator. MEAN 聚合器是将目标节点 v 的所有邻居节点特征和 v 节点自身特征求均值, 然后将得到的结果更新 v 节点的特征表示。这种将自身节点特征和邻居节点特征同等对待的方式不利于提取目标节点与邻居节点之间潜在的隐含关系。通常不同邻居节点对目标节点的影响是有所区别的, 而这种区别本文中使用的关系距离权重来表示, 即在 v 的所有邻居节点特征向 v 节点聚合的过程中引用关系距离权重, 从而区别每个节点对目标节点的不同影响程度, 其添加关系距离后 MEAN 聚合如下:

$$x_v^{(t+1)} = \phi(\text{mean}(\{x_v^t \cup \{x_u^t \times w_{uv}\}\})) \quad (6)$$

其中: w_{uv} 表示节点 v 的所有邻居边上的权重; x_u^t 为节点 v 的所有邻居节点特征。

(b) BiLSTM aggregator. 在 GraphSAGE^[17] 模型中与 MEAN 聚合器相比虽然 LSTM 聚合器有更强的表达能力, 但是由于在普通图中邻居节点不具备序列关系, 所以 LSTM 输入为邻居节点随机顺序, 这导致每次输入会得到不同的结果即不具有排列不变性。而对于句子关系图本身是一个包含序列信息的图, 为增强模型学习能力本文将 LSTM 聚合器换为 BiLSTM 聚合器, 如图 9 所示。




图 9 BiLSTM 聚合器

Fig. 9 BiLSTM aggregator

若节点 x_t 的邻居节点分别为 $x_{t+1}, x_{t-1}, x_{t-2}$ 且在句子中排序为 $x_{t+1}, x_t, x_{t-1}, x_{t-2}$ 。则使用 BiLSTM 聚合器更新目标节点 x_t 时, 首先将目标节点与其邻居节点按句子中顺序输入 BiLSTM 聚合器中, 输出隐藏层表示为 $h_{t+1}, h_t, h_{t-1}, h_{t-2}$, 然后使用目标节点 x_t 对应的输出 h_t 更新节点 x_t 。其中每一个 LSTM 单元有输入门 i 、遗忘门 f 、输出门 o 和记忆状态 c , 则隐藏层 h_t 更新公式为

$$\begin{aligned} i_t &= \sigma(W_i \cdot [h_{t-1}; x_t] + b_i) \quad f_t = \sigma(W_f \cdot [h_{t-1}; x_t] + b_f) \\ o_t &= \sigma(W_o \cdot [h_{t-1}; x_t] + b_o) \quad g_t = \tanh(W_g \cdot [h_{t-1}; x_t] + b_g) \\ c_t &= i_t \odot g_t + f_t \odot c_{t-1} \quad h_t = o_t \odot \tanh(c_t) \end{aligned} \quad (7)$$

其中: σ 为 sigmoid 函数; \odot 表示按位乘运行; x_t 为输入向量; $W_i, W_f, W_o \in \mathbb{R}^{(d/2) \times k}$; $b_i, b_f, b_o, b_g \in \mathbb{R}^{d/2}$ 。则 BiLSTM 向前隐藏层单元 $h_f = [\tilde{h}_1, \tilde{h}_2, \dots, \tilde{h}_k]$, 后向隐藏层单元 $h_b = [\tilde{h}_1, \tilde{h}_2, \dots, \tilde{h}_k]$, 其中 $h_f \in \mathbb{R}^{k \times d/2}$, $h_b \in \mathbb{R}^{k \times d/2}$, 拼接后 $h_t = [\tilde{h}_1, \tilde{h}_2]$, 即目标节点 v 的 BiLSTM 聚合为 $x_v^{t+1} = h_t = [\tilde{h}_1, \tilde{h}_2]$ 。

b) 边聚合。通常图中边的特征主要受边上节点特征和自身特征影响, 因此对于句子关系图上边特征更新为

$$e_{uv}^{t+1} = x_u^t \cdot (e_{uv}^t)^T \cdot x_v^t \quad (8)$$

其中: x_u^t, x_v^t 分别为边 (u, v) 上节点 u 和 v 的特征; $(e_{uv}^t)^T$ 为边 (u, v) 特征转置。

3.5 输出层

首先获取 3.4 节图网络层中训练得到的节点或边嵌入表示 g , 如式 (9) 所示。

$$g = x_v^{t+1} \mid e_{uv}^{t+1} \quad (9)$$

其中: \mid 表示或, 当为节点级任务时 $g = x_v^{t+1}$, 当为边级任务时 $g = e_{uv}^{t+1}$ 。然后使用 ReLU 激活函数的全连接层转换节点或边的隐藏表示, 如式 (10) 所示。

$$h' = \text{ReLU}(w_1 g + b_1) \quad (10)$$

其中: w_1, b_1 分别表示权重矩阵和偏置向量; $h' \in \mathbb{R}$ 为句子关系图最终的特征, 通过 softmax 计算 h' 在 y 中各个类别标签的概率分布。

$$y' = \text{softmax}(w_2 h' + b_2) \quad (11)$$

其中: w_2, b_2 分别为 softmax 的权重值和偏置值向量; $y' = (y_1, y_2, \dots, y_n)$ 表示图 G 节点和边在 y 类别上预测值的归一化结果。在 y' 预测值标签中取最大值 $\max(y')$ 作为模型最终预测结果, 即 $\hat{y} = \max(y')$ 。

3.6 模型训练

若 \hat{y} 是句子关系图 G 中节点和边的预测结果标签值, SRG 模型使用有监督的训练方法, 损失函数为预测标签和真实标签的交叉熵, 为避免模型在训练中出现过拟合使用 dropout 和 l_2 正则化。

$$\text{loss} = \sum_i \sum_j y_i^j \log \hat{y}_i^j + \sum_{\theta \in \phi} \lambda \theta^2 \quad (12)$$

其中: i 是图 G 索引; j 为类别索引; λ 为 l_2 正则项的系数; ϕ 为所有参数; y_i^j 为第 i 个图的实际类别; \hat{y}_i^j 为图 G 中对应的预测值。

4 实验

4.1 实验准备

为研究方面级情感分析, 文献 [18] 对 2014 年国际语义评测 SemEval^[19-21] 任务进行了方面和观点词的标注, 但其未标注情感极性。文献 [15] 在文献 [18] 基础上构建 AFOE 数据集, 该数据集新增了情感极性标注, 如表 1 为原始 AFOE 数据。其中: #A 表示方面词个数; #O 表示观点词个数; #S 表示句子个数; #T 表示由方面词、观点词和情感极性构成的三元组个数。然而以上数据集都只适用于序列任务, 无法直接用于 SRG

任务,为验证 SRG 模型的有效性,本文在文献[15]标注的 AFOE 数据集基础上将每个句子处理为节点集、边集、节点特征和边特征,处理后的数据集如表 2 所示。其中:#G 表示图个数;#A 表示图中为方面词的节点个数;#O 表示为观点词的节点个数;#NN 表示所有节点个数;#POS 表示边上标签为积极的边数;#ENG 表示标签为消极的边数;#NEU 表示标签为中性的边数;#EN 表示所有边数。

表 1 基于 SemEval 的原始 AFOE 数据
Tab. 1 Based on semeval's original AFOE data

| 14lap | | | | | | 15res | | | | | |
|----------|-------|------|------|------|------|----------|-------|------|------|------|------|
| datasets | | #S | #A | #O | #T | datasets | | #S | #A | #O | #T |
| 14lap | train | 1109 | 2295 | 2256 | 1568 | 15res | train | 744 | 1522 | 1469 | 1060 |
| | test | 328 | 705 | 639 | 458 | | test | 324 | 660 | 578 | 435 |
| 14res | train | 1569 | 3535 | 3377 | 2548 | 16res | train | 1073 | 2194 | 2057 | 1501 |
| | test | 487 | 1218 | 1112 | 840 | | test | 328 | 661 | 616 | 457 |

表 2 基于 AFOE 数据集的句子关系图数据集
Tab. 2 Sentence relation graph data set based on the AFOE data set

| datasets | | 节点 | | | | | | | 边 | | | |
|----------|-------|-------|-------|-------|--------|-------|------|------|--------|--|--|--|
| | | #G | #A | #O | #NN | #POS | #NEG | #NEU | #EN | | | |
| 14lap | train | 1 109 | 2 277 | 1 947 | 21 155 | 847 | 573 | 148 | 9 342 | | | |
| | test | 328 | 704 | 565 | 5 127 | 295 | 101 | 62 | 7 936 | | | |
| 14res | train | 1 569 | 3 515 | 2 975 | 26 711 | 1 804 | 537 | 207 | 41 438 | | | |
| | test | 487 | 1 210 | 956 | 7 909 | 641 | 140 | 59 | 12 245 | | | |
| 15res | train | 744 | 1 522 | 1 375 | 10 891 | 811 | 217 | 32 | 16 680 | | | |
| | test | 324 | 660 | 551 | 5 110 | 293 | 123 | 19 | 7 856 | | | |
| 16res | train | 1 073 | 2 194 | 1 935 | 16 095 | 1 107 | 343 | 51 | 24 684 | | | |
| | test | 328 | 657 | 571 | 4 828 | 359 | 72 | 25 | 7 385 | | | |

4.2 实验设置和评估指标

针对邻接矩阵标注方案,由于在边标记中 N 标签占比远大于其他标记类别,导致数据类别不平衡。为解决该问题,本文设置关系距离权重阈值 weight gate,当关系距离权重小于设置阈值时不参与图计算。在模型训练过程中,为使模型训练效果更加有效且便于实验比较,分别对 SRG-MEAN 和 SRG-BiLSTM 模型的参数进行了预设置,并选用不同的优化器进行优化,模型参数和优化器选择如表 3 所示。

表 3 参数设置
Tab. 3 Parameter setting

| 参数及优化器 | SRG-mean | SRG-BiLSTM | 参数及优化器 | SRG-mean | SRG-BiLSTM |
|------------------|----------|------------|--------------|----------|------------|
| 批处理大小 batch-size | 32 | 32 | dropout rate | 0.5 | 0.5 |
| 迭代次数 epochs | 50 | 50 | 层数 | 4 | 4 |
| 正则化系数 | 0.000 1 | 0.000 1 | 优化函数 | RMSProp | Adam |
| 学习率 | 0.01 | 0.01 | weight gate | 0.28 | 0.24 |

本文采用准确率 (accuracy)、精确率 P (precision)、召回率 (recall) 和 F_1 值 (macro average) 等评价指标。设 TP 是正确预测的样本,FP 是其他类别被判定为当前类别的样本,FN 是当前类别被错误判定为其他类别的样本,则准确率、精确率、召回率和 F_1 值的计算公式为

$$accuracy = \frac{\sum_{i=1}^m TP_i}{\sum_{i=1}^m (TP_i + FP_i + FN_i)} \quad P = \frac{TP}{TP + FP} \quad (13)$$

$$recall = \frac{TP}{TP + FN} \quad F_1 = \frac{2 \times P \times recall}{P + recall} \quad (14)$$

4.3 实验算法流程

为验证 3.1 节中定义的两个任务在 SRG 模型上的表现效果,本文按照以下实验算法执行:

a) 在文献[15]构建的数据集基础上利用斯坦福开源的语法分析器获取句子依存语法树结构,在依存句法树上添加单词序列边构成句子关系图,根据 1.3 节中算法计算关系距离权重值。

b) 利用 GloVe 预训练词向量^[16]分别将句子关系图中节点特征(单词)和边特征(依存关系)映射成对应的词向量矩阵,节点类别标签和边类别标签分别转换为 one-hot 编码。

c) 根据第 3 章所描述的内容构建句子关系图模型,该模型分别完成节点分类任务和边分类任务,在两个任务中根据聚合器的不同设置相应的对比实验。

d) 为验证关系距离权重对 SRG 模型分类效果影响,分别设置有权重值参与图计算和无权重值参与图计算的对比实验,同时通过实验设置不同权重阈值找到为解决标签不平衡而提出的最佳权重阈值。

4.4 实验 1 句子关系图中节点分类实验及对比

该实验的目的是抽取图中方面项和观点项的节点,属于图中节点级任务,即抽取句子中涉及到的方面词和观点词。为了分析 SRG 模型在方面项和观点项抽取的效果,本实验直接使用文献[15]在观点抽取任务中引用的模型实验结果和 GTS 模型^[15]的结果作为基准进行比较,涉及到的基准方法模型简介如下:

a) CMLA 模型^[22]。基于注意力机制提出多层耦合注意力,在模型每一层中对每个句子都构造一对注意力,一个用于方面术语提取,另外一个用于观点术语提取,然后捕捉方面术语和观点术语之间的直接关系,该模型不依赖于任何句法和解析器。

b) RINANTE 模型^[23]。使用基于规则的方法从数据集中提取方面和观点术语,然后利用基于 BiLSTM + CRF 的神经网络对方面和观点术语进行抽取。该神经网络中用人工标注的数据作为监督,而使用基于规则的数据作为弱监督进行训练。

c) C-GCN 模型^[24]。利用依赖树捕捉单词之间的长距离依赖关系,通过以路径为中心的修剪策略对依赖树进行修剪并作为输入树,然后利用图卷积网络在依赖树上进行编码,实验表明基于依赖关系的模型与序列模型具有互补的优势。

d) DE-CNN 模型^[25]。本文提出对于方面和观点术语抽取利用简单的 CNN 模型加上领域词向量就能有效提高抽取性能,本文直接拼接两种词向量,将拼接的结果放入 CNN 中,然后再进行一个全连接层。

e) GTS 模型^[15]。本文首先在 SemEval 数据集基础上构建了 AFOE 数据集,针对该数据集提出网格标注方案并通过 CNN、LSTM 和 BERT 验证标注方案的有效性。

为验证 SRG 模型中 MEAN 和 BiLSTM 聚合器在句子关系图、最大关系子图和最小关系子图的效果,分别记 SRG-mean 和 SRG-BiLSTM 为在句子关系图上的模型,SRG-max-mean 和 SRG-max-BiLSTM 为在最大关系子图上的模型,SRG-min-mean 和 SRG-min-BiLSTM 为在最小关系子图上的模型。各模型表现效果如表 4 所示,SRG 模型在方面项和观点项抽取任务上整体表现优于现有模型,这表明融合句子依存树和句子中单词序列信息的句子关系图在方面项和观点项抽取中性能有所提升。SRG 模型采用与目标节点关系最紧密的节点特征和目标节点本身的特征来更新目标节点的表示,相对于其他只考虑句子中单词序列或只考虑句子依存句法关系的模型,句子关系图在一定程度上保留了单词之间隐含关系,这也证明只考虑单方面的方法会使模型不能完全获取单词之间潜在的关系特征,从而制约模型的性能。

a) 不同聚合器性能比较。从表 4 中 SRG 模型可知,在 SRG 模型的节点级任务中,节点的聚合方式对模型效果影响很大,总体来说使用 BiLSTM 聚合器模型的表现性能优于使用 MEAN 聚合器的模型,虽然 MEAN 聚合器中添加了关系距离权重,但其表现效果相对于 BiLSTM 聚合器只有在 14 res 和 15 res 数据集上有所提升,在其他数据集上表现有所下降。而对于 BiLSTM 聚合器整体表现性能最好,经分析其主要原因在于 BiLSTM 本身对序列问题表现极佳,再加之输入为句子中关系最密切的单词过滤了无关单词使得 BiLSTM 聚合器能更大程度获取相关单词的关系,从而使得整体性能优于其他模型。

b) 不同关系图的性能比较。本文模型中使用了三种不同

的关系图,从表 3 中 SRG 模型表现来看,使用最小关系子图对模型训练效果最好,这表明在句子关系图中修剪无关节点对模型性能提升是有帮助的。原始句子关系图中保留了所有单词之间的依存关系和序列关系,其中也保留了大量与目标节点无关的节点,这些无关节点影响模型对目标节点的抽取。对于最

大关系子图,虽然消除了无关节点,但是对有多对方面项和观点项的句子,最大关系子图仍然保留它们之间无关的联系。而最小关系子图是以句子中一对方面和观点项为中心的图,最大程度消除了无关节点和边,保证模型能获得与目标节点关系最紧密的信息从而提高模型性能。

表 4 节点分类模型对比

Tab.4 Node classification models performances

| methods | 14lap | | | 14res | | | 15res | | | 16res | | |
|-------------------|----------|----------|----------------------|----------|----------|----------------------|----------|----------|----------------------|----------|----------|----------------------|
| | <i>P</i> | <i>R</i> | <i>F₁</i> | <i>P</i> | <i>R</i> | <i>F₁</i> | <i>P</i> | <i>R</i> | <i>F₁</i> | <i>P</i> | <i>R</i> | <i>F₁</i> |
| CMLA + Dis-BiLSTM | 59.47 | 45.23 | 51.17 | 77.21 | 52.14 | 62.24 | 64.86 | 44.33 | 52.47 | 66.29 | 50.82 | 57.33 |
| CMLA + C-GCN | 60.69 | 47.25 | 53.03 | 72.22 | 56.35 | 63.17 | 64.31 | 49.41 | 55.76 | 66.61 | 59.23 | 62.70 |
| RINANTE + C-GCN | 67.38 | 52.10 | 58.76 | 71.07 | 59.45 | 64.69 | 65.52 | 42.74 | 51.73 | — | — | — |
| DE-CNN + IOG | 59.59 | 51.68 | 55.35 | 67.70 | 69.41 | 68.55 | 56.18 | 60.08 | 58.04 | 62.97 | 66.22 | 64.55 |
| RINANTE + IOG | 61.76 | 53.11 | 57.10 | 70.16 | 65.47 | 67.74 | 63.24 | 55.57 | 59.16 | — | — | — |
| GTS-CNN | 68.33 | 55.04 | 60.97 | 74.13 | 69.49 | 71.74 | 66.81 | 61.34 | 63.96 | 70.48 | 72.39 | 71.42 |
| GTS-BiLSTM | 61.53 | 54.31 | 57.69 | 71.32 | 67.07 | 69.13 | 67.76 | 63.19 | 65.39 | 70.32 | 70.46 | 70.39 |
| GTS-BERT | 66.41 | 64.95 | 65.67 | 76.23 | 74.84 | 75.53 | 66.40 | 68.71 | 67.53 | 71.70 | 77.79 | 74.62 |
| SRG-mean(本文) | 64.82 | 54.71 | 59.40 | 67.60 | 61.80 | 64.17 | 67.80 | 62.56 | 65.88 | 68.04 | 53.27 | 59.75 |
| SRG-LSTM(本文) | 68.51 | 65.62 | 67.03 | 77.21 | 66.32 | 71.35 | 77.17 | 63.36 | 69.58 | 72.47 | 68.46 | 70.40 |
| SRG-max-mean(本文) | 65.65 | 55.03 | 59.87 | 74.98 | 66.96 | 70.74 | 76.46 | 66.94 | 71.38 | 66.03 | 58.33 | 61.94 |
| SRG-max-LSTM(本文) | 70.74 | 66.15 | 68.36 | 78.40 | 70.58 | 74.28 | 77.46 | 63.03 | 69.50 | 73.68 | 58.36 | 65.13 |
| SRG-min-mean(本文) | 66.38 | 62.24 | 64.24 | 71.56 | 65.17 | 68.21 | 75.42 | 67.09 | 71.01 | 64.18 | 58.92 | 61.43 |
| SRG-min-LSTM(本文) | 72.25 | 65.93 | 68.94 | 81.15 | 78.50 | 79.80 | 78.85 | 71.02 | 74.73 | 79.82 | 69.67 | 74.45 |

4.5 实验 2 句子关系图中边分类实验及对比

SRG 模型中边级任务属于方面级情感分析任务。为了评估 SRG 模型在边上情感分类任务的准确性,本文直接与文献[15]在观点三元组抽取任务中引用的基准方法及 GTS 模型^[15]和 OTM 模型^[2]进行比较,使用的基准模型如下:

a) Peng-unified 模型^[26]。本文提出将方面项、观点项和情感极性作为方面级情感分析中的子任务并将其命名为方面情感三元组抽取,通过基于 BiLSTM 和 GCN 模型对所给数据进行单元组抽取。

b) OTE-MTL 模型^[2]。首先将三元组抽取过程分为预测阶段和解码阶段,在基于词嵌入和 BiLSTM 对句子进行编码从而学习方面项和观点项的抽象表示,抽象中由方面标记、观点标记和单词的情感依赖组成,在检测到方面、观点和依赖后执行基于启发式规则的解码生成三元组。

c) JET 模型^[27]。本文通过提出位置感知标记方案实现观点三元组抽取任务,方案能够指定句子结构信息且基于该方案提出 JET 模型,模型通过丰富的标签语义实现三元组之间的连接信息抽取。

d) GTS 模型^[15]。文献[15]提出的 GTS 模型除了方面和观点对抽取外还包括观点三元组抽取,因此实验 2 中同样使用 GTS 中观点三元组任务作为基准对比。

表 5 边分类模型对比

Tab.5 Edge classification models performances

| methods | 14lap | | | 14res | | | 15res | | | 16res | | |
|----------------------|----------|----------|----------------------|----------|----------|----------------------|----------|----------|----------------------|----------|----------|----------------------|
| | <i>P</i> | <i>R</i> | <i>F₁</i> | <i>P</i> | <i>R</i> | <i>F₁</i> | <i>P</i> | <i>R</i> | <i>F₁</i> | <i>P</i> | <i>R</i> | <i>F₁</i> |
| Peng-unified-R + PD | 40.40 | 47.24 | 43.50 | 41.18 | 62.99 | 51.89 | 40.97 | 54.68 | 46.79 | 46.79 | 62.97 | 53.62 |
| Peng-unified-R + IOG | 48.62 | 45.52 | 47.02 | 58.89 | 60.41 | 59.64 | 51.70 | 46.04 | 48.71 | 59.25 | 58.09 | 58.67 |
| OTE-MTL | 50.52 | 39.71 | 44.31 | 66.04 | 56.25 | 60.62 | 57.51 | 43.96 | 49.76 | 64.68 | 54.97 | 59.36 |
| OTE-MTL-Inter | 47.66 | 41.85 | 44.43 | 66.24 | 54.38 | 59.61 | 49.32 | 46.12 | 47.33 | 47.33 | 57.71 | 53.06 |
| JET | 55.39 | 47.33 | 51.04 | 70.56 | 55.94 | 62.40 | 64.45 | 51.96 | 57.53 | 70.42 | 58.37 | 63.83 |
| GTS-CNN | 55.93 | 47.52 | 51.38 | 70.79 | 61.71 | 65.94 | 60.09 | 53.57 | 56.64 | 62.63 | 66.98 | 64.73 |
| GTS-BiLSTM | 59.42 | 45.13 | 51.30 | 67.28 | 61.91 | 64.49 | 63.26 | 50.71 | 56.29 | 66.07 | 65.05 | 65.56 |
| GTS-BERT | 57.52 | 51.92 | 54.58 | 70.92 | 69.49 | 70.20 | 59.29 | 58.07 | 58.67 | 68.58 | 66.60 | 67.58 |
| SRG-mean(本文) | 43.93 | 44.97 | 44.47 | 56.49 | 44.88 | 50.02 | 55.25 | 48.75 | 51.79 | 53.33 | 50.00 | 50.59 |
| SRG-LSTM(本文) | 57.30 | 51.96 | 51.66 | 62.15 | 54.40 | 58.11 | 63.09 | 57.69 | 60.27 | 60.93 | 62.81 | 61.85 |
| SRG-max-mean(本文) | 61.36 | 58.86 | 60.08 | 66.49 | 62.38 | 64.36 | 65.05 | 55.45 | 59.86 | 51.35 | 47.69 | 49.45 |
| SRG-max-LSTM(本文) | 65.45 | 60.41 | 62.36 | 73.81 | 67.02 | 70.27 | 68.39 | 57.69 | 62.58 | 63.81 | 63.02 | 63.41 |
| SRG-min-mean(本文) | 60.69 | 61.14 | 60.95 | 68.15 | 65.48 | 66.78 | 64.60 | 62.99 | 63.78 | 57.75 | 50.93 | 54.12 |
| SRG-min-LSTM(本文) | 60.37 | 61.51 | 60.93 | 74.60 | 77.08 | 75.81 | 66.67 | 58.33 | 62.22 | 61.01 | 58.33 | 59.63 |

表 6 关系距离权重对 MEAN 聚合器的影响
Tab. 6 Influence of relational distance weight on MEAN aggregator

| methods | 14res | | |
|-------------|-------|-------|-------|
| | P | R | F_1 |
| SRG-mean-no | 40.35 | 33.33 | 46.29 |
| SRG-mean | 61.40 | 60.61 | 64.95 |

4.7 关系距离权重阈值设置分析

设置关系距离权重阈值目的是缓解邻接矩阵标注方案中边标签不均衡问题,由式(3)可知关系距离权重取值范围为 $w_e \in (\tan(0), \tan(1))$,用 \tan 函数对归一化的关系距离进行放缩。为减少由于关系距离权重阈值过大而导致过度过滤节点和边的影响,实验中将关系距离权重阈值设置在 $[0, 0.4]$ 进行实验,如图 10 和 11 所示。从关系距离权重阈值对 MEAN 聚合器影响可知权重阈值对三种关系图影响趋于平缓,尤其当阈值设置在 $0.24 \sim 0.36$ 时三种关系图上模型均取得最佳效果。而对于 BiLSTM 聚合器,其受关系距离权重阈值影响波动较大,但其阈值在 $0.16 \sim 0.32$ 时三种关系图上效果相对均取得最佳表现。综上为使模型能取得最佳效果,MEAN 聚合器上的关系距离权重阈值设置为 0.28 ,BiLSTM 聚合器上的关系距离权重阈值设置为 0.24 。总的来说无论关系距离权重阈值为多少,最

大关系子图和最小关系子图的表现效果均优于句子关系图,尤其最小关系子图效果表现较为平缓,这也是最小关系子图仅保留与目标节点邻居节点的原因。




图 10 关系距离权重阈值对 MEAN 聚合器影响
Fig. 10 Influence of relation distance weight gate on mean aggregator




图 11 关系距离权重阈值对 BiLSTM 聚合器影响
Fig. 11 Influence of relation distance weight gate on BiLSTM aggregator

4.8 案例分析

为更好地分析模型效果,本文在测试集中选出两个例句并利用文献[15]开源的 GTS 和 SRG-min-LSTM 模型进行测试分析,测试结果如表 7 所示。对于第一个例句“The price is reasonable although the service is poor.”,两个模型都能正确抽取其中方面项和观点项并且能正确分析情感极性。

表 7 案例对比
Tab. 7 Case study

| case | ground true | | GTS | | SRG-min-LSTM | |
|--|----------------|------------------------|----------------|------------------------|----------------|------------------------|
| | aspect/opinion | opinion triplets | aspect/opinion | opinion triplets | aspect/opinion | opinion triplets |
| The price is reasonable although the service is poor. | price - A | | price - A | | price - A | |
| | service - A | (price reasonable pos) | service - A | (price reasonable pos) | service - A | (price reasonable pos) |
| | reasonable - O | (service poor neg) | reasonable - O | (service poor neg) | reasonable - O | (service poor neg) |
| The food, though served with bad service, is actually great. | food - A | | food - A | | food - A | |
| | service - A | (food great pos) | service - A | (food bad neg) | served - A | (food great pos) |
| | bad - O | (service bad neg) | bad - A | (service bad neg) | service - A | (served bad neg) |
| | great - O | | | | bad - O | (service bad neg) |
| | | | | | great - O | |

注: X-A 表示 X 为方面词; X-O 表示 X 为观点词。

第二个例句“The food, though served with bad service, is actually great.”属于复杂句。GTS 模型在进行方面项和观点项抽取时并没有抽取完整,同时在进行情感分析时错误地将 food 的观点词识别为 bad 导致 food 方面情感极性为消极。而 SRG 模型中多余地将 served 识别为方面项,错误地得到 served 方面情感极性为消极。在 SRG 模型中可能导致该错误原因之一是 SRG 模型未能将 served with 识别为短语而是将 served 作为个体,而 served 也具有服务的意思。

5 结束语

目前处理方面级情感分析任务的主流方法是将句子视为序列任务利用各种语法结构和位置信息使神经网络能有效捕捉单词之间的隐含表示。本文中提出一种新的解决方案,即融合句子中单词序列信息和单词之间依存句法信息构建句子关系图,利用图神经网络捕捉句子关系图中节点之间的隐含特征从而对节点和边完成分类任务。实验表明,利用句子关系图解决方面级情感分析任务是有效的,且相对于目前最好的方法有所提高。在节点聚合中使用不同的聚合器对模型表现影响很大,同样在边分类中由于分类样本不均衡,即便利用关系距离权重进行欠采样处理,但模型效果仍然受到分类样本不均衡的影响。因此在接下来的工作中将进一步完善节点聚合方案,比如引入注意力机制等,采用不同的方案处理样本不均衡等问题。

参考文献:

[1] Liu Bing. Sentiment analysis and opinion mining[M]. [S. l.]: Mor-

- gan & Claypool 2012.
- [2] Zhang Chen, Li Qiuchi, Song Dawei, et al. A multi-task learning framework for opinion triplet extraction [EB/OL]. (2020-10-31). <https://arxiv.org/abs/2010.01512>.
- [3] Jiang Long, Yu Mo, Zhou Ming, et al. Target-dependent twitter sentiment classification[C]//Proc of the 49th Annual Meeting of the Association for Computational Linguistics: Human Language Technologies. Portland, Oregon: Association for Computational Linguistics, 2011: 151-160.
- [4] Dong Li, Wei Furu, Tan Chuanqi, et al. Adaptive recursive neural network for target-dependent twitter sentiment classification [C]//Proc of the 52nd Annual Meeting of the Association for Computational Linguistics (volume 2: short papers). Baltimore, Maryland: Association for Computational Linguistics Press, 2014: 49-54.
- [5] Tang Duyu, Qin Bing, Feng Xiaocheng, et al. Effective LSTMs for target-dependent sentiment classification [EB/OL]. (2016-09-29). <https://arxiv.org/abs/1512.01100>.
- [6] Wang Yequan, Huang Minlie, Zhu Xiaoyan, et al. Attention-based LSTM for aspect-level sentiment classification [C]//Proc of Conference on Empirical Methods in Natural Language Processing. 2016: 606-615.
- [7] Chen Peng, Sun Zhongqian, Bing Lidong, et al. Recurrent attention network on memory for aspect sentiment analysis [C]//Proc of Conference on Empirical Methods in Natural Language Processing. Copenhagen, Denmark: Association for Computational Linguistics, 2017: 452-461.
- [8] Fan Feifan, Feng Yansong, Zhao Dongyan. Multi-grained attention network for aspect-level sentiment classification [C]//Proc of Conference on Empirical Methods in Natural Language Processing. 2018: 3433-3442.
- (下转第 3585 页)

- [5] Sabidussi G. The centrality index of a graph[J]. *Psychometrika*, 1966 31(4): 581-603.
- [6] Hage P, Harary F. Eccentricity and centrality in networks[J]. *Social Networks*, 1995 17(1): 57-63.
- [7] Lyu Linyuan, Zhang Yicheng, Yeung C H, et al. Leaders in social networks, the delicious case[J]. *PLoS One* 2011 6(6): e21202.
- [8] 王建伟, 荣莉莉, 郭天柱. 一种基于局部特征的网络节点重要性度量方法[J]. *大连理工大学学报*, 2010 50(5): 822-826. (Wang Jianwei, Rong Lili, Guo Tianzhu. A new measure method of network node importance based on local characteristics[J]. *Journal of Dalian University of Technology* 2010 50(5): 822-826.)
- [9] Chen Duanbing, Lyu Linyuan, Shang Mingsheng, et al. Identifying influential nodes in complex networks[J]. *Physica A: Statistical Mechanics and Its Applications* 2012 391(4): 1777-1787.
- [10] Kitsak M, Gallos L K, Havlin S, et al. Identification of influential spreaders in complex networks[J]. *Nature Physics* 2010 6(11): 888-893.
- [11] Nie Tingyuan, Guo Zheng, Zhao Kun, et al. Using mapping entropy to identify node centrality in complex networks[J]. *Physica A: Statistical Mechanics and Its Applications* 2016 453(7): 290-297.
- [12] 阮逸润, 老松杨, 王竣德, 等. 基于领域相似度的复杂网络节点重要度评估算法[J]. *物理学报*, 2017 66(3): 038902. (Ruan Yirun, Lao Songyang, Wang Junde, et al. Node importance measurement based on neighborhood similarity in complex network[J]. *Acta Physica Sinica* 2017 66(3): 038902.)
- [13] 郑文萍, 吴志康, 杨贵. 一种基于局部中心性的网络关键节点识别算法[J]. *计算机研究与发展* 2019 56(9): 1872-1880. (Zheng Wenping, Wu Zhikang, Yang Gui. A novel algorithm for identifying critical nodes in networks based on local centrality[J]. *Journal of Computer Research and Development* 2019 56(9): 1872-1880.)
- [14] Ruan Yirun, Tang Jun, Hu Yanli, et al. Efficient algorithm for the identification of node significance in complex network[J]. *IEEE Access* 2020 8: 28947-28955.
- [15] Yang Haihua, An Shi. Critical nodes identification in complex networks[J]. *Symmetry* 2020 12(1): 123-136.
- [16] Teng Xian, Pei Sen, Morone F, et al. Collective influence of multiple spreaders evaluated by tracing real information flow in large-scale social networks[J]. *Scientific Reports* 2016 6(1): 36043.
- [17] Meo P D, Levene M, Messina F, et al. A general centrality framework-based on node navigability[J]. *IEEE Trans on Knowledge and Data Engineering* 2020 32(11): 2088-2100.
- [18] 孔江涛, 黄健, 龚建兴, 等. 基于复杂网络动力学模型的无向加权网络节点重要性评估[J]. *物理学报* 2018 67(9): 098901. (Kong Jiangtao, Huang Jian, Gong Jianxing, et al. Evaluation methods of node importance in undirected weighted networks based on complex network dynamics models[J]. *Acta Physica Sinica* 2018 67(9): 098901.)
- [19] 王哲, 李建华, 康东. 基于极大连通子图边界的复杂网络恢复研究[J]. *系统仿真学报* 2020 32(12): 2306-2316. (Wang Zhe, Li Jianhua, Kang Dong. Research on recovering of complex networks based on boundary nodes of giant connected component[J]. *Journal of System Simulation* 2020 32(12): 2306-2316.)
- [20] Latora V, Marchiori M. A measure of centrality based on the network efficiency[J]. *New Journal of Physics* 2007 9(6): 188.
- [21] 陆靖桥, 傅秀芬, 蒙在桥. 复杂网络的鲁棒性与中心性指标的研究[J]. *计算机应用与软件*, 2016 33(4): 302-305, 309. (Lu Jingqiao, Fu Xiufen, Meng Zaiqiao. Research on robustness and centrality metrics of complex networks[J]. *Computer Applications and Software* 2016 33(4): 302-305, 309.)
- [22] Gleiser P M, Danon L. Community structure in Jazz[J]. *Advances in Complex Systems* 2003 6(4): 565-573.
- [23] Blagus N, Šubelj L, Bajec M. Self-similar scaling of density in complex real-world networks[J]. *Physica A: Statistical Mechanics and Its Applications* 2012 391(8): 2794-2802.
- [24] Rossi R A, Ahmed N K. An interactive data repository with visual analytics[J]. *ACM SIGKDD Explorations Newsletter* 2016 17(2): 37-41.
- [25] Newman M E J. Finding community structure in networks using the eigenvectors of matrices[J]. *Physical Review E* 2006 74(3): 036104.
- [26] Sun Xiaoqian, Gollnick V, Wandelt S. Robustness analysis metrics for worldwide airport network: a comprehensive study[J]. *Chinese Journal of Aeronautics* 2017 30(2): 500-512.
- [27] Von Mering C, Krause R, Snel B, et al. Comparative assessment of large-scale data sets of protein-protein interactions[J]. *Nature*, 2002 417(6887): 399-403.

(上接第3580页)

- [9] 刘丹, 昌茜, 王拂林. 基于自注意力机制的方面情感分类[J]. *计算机应用研究* 2020 37(11): 3227-3231, 3245. (Liu Dan, Chang Xi, Wang Fulin. Aspect-level sentiment classification based on self-attention mechanism[J]. *Application Research of Computers*, 2020 37(11): 3227-3231, 3245.)
- [10] He Ruidan, Lee W S, Ng H T, et al. Effective attention modeling for aspect-level sentiment classification[C]//Proc of the 27th International Conference on Computational Linguistics. 2018: 1121-1131.
- [11] Sun Kai, Zhang Richong, Mensah S, et al. Aspect-level sentiment analysis via convolution over dependency tree[C]//Proc of Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing. 2019: 5683-5692.
- [12] Huang Binxuan, Carley K M. Syntax-aware aspect level sentiment classification with graph attention networks[EB/OL]. (2019-09-05). <https://arxiv.org/abs/1909.02606>.
- [13] Wang Kai, Shen Weizhou, Yang Yunyi, et al. Relational graph attention network for aspect-based sentiment analysis[EB/OL]. (2020-04-26). <https://arxiv.org/abs/2004.12362>.
- [14] Huang Binxuan, Carley K M. Parameterized convolutional neural networks for aspect level sentiment classification[EB/OL]. (2019-09-13). <https://arxiv.org/abs/1909.06276>.
- [15] Wu Zhen, Ying Chengcan, Zhao Fei, et al. Grid tagging scheme for aspect-oriented fine-grained opinion extraction[EB/OL]. (2020-11-03). <https://arxiv.org/abs/2010.04640>.
- [16] Pennington J, Socher R, Manning C D. GloVe: global vectors for word representation[C]//Proc of Conference on Empirical Methods in Natural Language Processing. 2014: 1532-1543.
- [17] Hamilton W L, Ying R, Leskovec J. Inductive representation learning on large graphs[EB/OL]. (2018-09-10). <https://arxiv.org/abs/1706.02216>.
- [18] Fan Zhifang, Wu Zhen, Dai Xinyu, et al. Target-oriented opinion-words extraction with target-fused neural sequence labeling[C]//Proc of Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 2019: 2509-2518.
- [19] Manandhar S. SemEval-2014 task 4: aspect based sentiment analysis[C]//Proc of the 8th International Workshop on Semantic Evaluation. 2014: 27-35.
- [20] Pontiki M, Galanis D, Papageorgiou H, et al. SemEval-2016 task 5: aspect based sentiment analysis[C]//Proc of International Workshop on Semantic Evaluation. 2016: 19-30.
- [21] Pontiki M, Galanis D, Papageorgiou H, et al. SemEval-2015 task 12: aspect based sentiment analysis[C]//Proc of the 9th International Workshop on Semantic Evaluation (SemEval 2015). 2015: 486-495.
- [22] Wang W, Pan S J, Dahlmeier D, et al. Coupled multi-layer attentions for co-extraction of aspect and opinion terms[C]//Proc of AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2017: 3316-3322.
- [23] Dai Hongliang, Song Yangqiu. Neural aspect and opinion term extraction with mined rules as weak supervision[EB/OL]. (2019-07-07). <https://arxiv.org/abs/1907.03750>.
- [24] Zhang Yuhao, Qi Peng, Manning C D. Graph convolution over pruned dependency trees improves relation extraction[EB/OL]. (2018-09-26). <https://arxiv.org/abs/1809.10185>.
- [25] Xu Hu, Liu Bing, Shu Lei, et al. Double embeddings and CNN-based sequence labeling for aspect extraction[EB/OL]. (2018-05-11). <https://arxiv.org/abs/1805.04601>.
- [26] Peng Haiyun, Xu Lu, Bing Lidong, et al. Knowing what, how and why: a near complete solution for aspect-based sentiment analysis[C]//Proc of AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press 2020: 8600-8607.
- [27] Xu Lu, Li Hao, Lu Wei, et al. Position-aware tagging for aspect sentiment triplet extraction[EB/OL]. (2021-03-09). <https://arxiv.org/abs/2010.02609>.